

Previsione dei prezzi di vendita delle abitazioni attraverso tecniche di Data Mining

Perrelli Adalgisa, m. 865028

Introduzione e descrizione del dataset

In questo elaborato si affronta il problema di individuare il modello più efficace per prevedere il prezzo di vendita delle abitazioni nella città di Milano. L'attenzione è stata posta in particolare sulle fasi di pre-processing e pulizia dei dati, con un focus specifico sull'imputazione dei valori mancanti. Le scelte effettuate hanno avuto l'obiettivo di rendere il dataset più coerente e informativo, facilitando l'emersione di relazioni e pattern utili alla successiva modellizzazione. Per quanto riguarda i valori anomali, è stato adottato un approccio deliberatamente conservativo, intervenendo solo sui casi più critici, così da preservare il più possibile la naturale variabilità dei dati.

L'analisi si è basata sui due dataset forniti: `training` e `test`. Il primo, composto da 8000 osservazioni, 15 variabili e dalla variabile risposta **selling_price**, è stato utilizzato per la stima dei modelli e per la selezione del modello con le prestazioni migliori. Il secondo, costituito da 4800 osservazioni e dalle stesse variabili del training (ad esclusione di **selling_price**), è stato impiegato per la valutazione finale delle previsioni.

Per garantire uniformità nelle operazioni di pre-processing, i due dataset sono stati inizialmente combinati in un unico oggetto, in modo da applicare le stesse trasformazioni e strategie di imputazione a tutte le osservazioni. Solo in un secondo momento, una volta completata la fase di pulizia e preparazione dei dati, il dataset integrato è stato suddiviso nelle componenti di training e test per procedere con la costruzione e la valutazione dei modelli predittivi.

Come misura d'errore è stato calcolato il *Mean Absolute Error (MAE)*, dato dalla media degli scarti in valore assoluto tra valori osservati e previsti dal modello.

Ogni riga del dataset rappresenta un'unità abitativa situata nella città di Milano, descritta da un insieme di variabili che ne caratterizzano diverse dimensioni. Queste variabili possono essere raggruppate nelle seguenti categorie:

1. **Descrittive** Raccolgono informazioni sull'immobile in termini di qualità (condizione), dimensioni (metratura), configurazione interna (numero di bagni e di stanze), piano, classe energetica, presenza di ascensore, posto auto, tipo di riscaldamento e ulteriori dotazioni (ad esempio balcone, esposizione, infissi, ecc.). In questa categoria rientra anche la variabile di disponibilità, che non descrive l'immobile dal punto di vista fisico ma risulta spesso rilevante ai fini della decisione d'acquisto.
2. **Strutturali** Descrivono le caratteristiche fisiche dell'edificio in cui è inserita l'unità abitativa, come il numero totale di piani e l'anno di costruzione.
3. **Geografiche** Forniscono informazioni sulla localizzazione dell'immobile. In particolare, la variabile **zone** identifica il quartiere di appartenenza e presenta 149 modalità distinte. L'elevato numero di livelli rende necessarie scelte modellistiche attente per evitare fenomeni di over fitting, soprattutto nelle zone meno rappresentate.
4. **Economiche** Riguardano variabili direttamente collegate ai costi o al valore dell'immobile, come le spese condominiali, che contribuiscono a definire l'onerosità complessiva dell'abitazione per l'acquirente.

Tra le variabili disponibili si è deciso di eliminare **ID**, in quanto funge unicamente da identificativo univoco delle osservazioni e non apporta informazione utile ai fini predittivi. La variabile risposta di interesse è **selling_price**, ossia il prezzo di vendita (osservato o atteso) dell'abitazione, espresso in euro. Per migliorare la normalità della distribuzione e attenuare l'effetto degli outlier, la risposta è stata trasformata in $\log(\text{selling_price}/\text{square_meters})$, cioè il logaritmo del prezzo al metro quadro (**lpsm**). Questa scelta, comune nell'analisi dei dati immobiliari, permette ai modelli di apprendere in funzione dei determinanti del valore per unità di superficie, piuttosto che sul prezzo complessivo dell'immobile.

Operazioni di pre-processing e feature engineering

La fase di pre-processing ha riguardato sia l'imputazione sistematica dei valori mancanti, sia la costruzione di nuove variabili derivate, con l'obiettivo di rendere i dati più coerenti, informativi e adatti alla modellizzazione.

Per la variabile **availability** si è scelto di trasformarla in indicatore binario (0/1), imputando i valori mancanti a 0. Questa scelta interpreta l'assenza di informazione come "non disponibile" e semplifica l'utilizzo della variabile nei modelli.

Per **rooms_number** e **bathrooms_number** si è innanzitutto ricondotta la codifica testuale ("5+", "3+") a valori numerici massimi plausibili (rispettivamente 6 e 4). Successivamente si è imposto un vincolo di coerenza indicando che il numero di bagni non superi il numero di stanze; i casi incoerenti sono stati posti a NA. I valori mancanti di **bathrooms_number** sono poi stati imputati tramite una tabella di contingenza, sfruttando la relazione empirica tra numero di stanze e numero di bagni: per ogni valore di **rooms_number** è stato assegnato il numero di bagni più frequentemente osservato.

Per **square_meters** è stata effettuata una pulizia preliminare degli outlier: sono stati marcati come mancanti i valori molto piccoli (≤ 12 mq) e quelli estremi, 800 mq, in quanto non plausibili rispetto alla tipologia di immobili considerata. È stata inoltre analizzata la superficie per numero totale di stanze (bagni + stanze) per verificare la ragionevolezza del rapporto mq/stanza. I valori mancanti così ottenuti sono stati imputati tramite un modello di regressione lineare su $\log(\text{square_meters})$ con predittori **rooms_number** e **bathrooms_number**, quindi riportati alla scala originale mediante esponenziale. In questo modo si sfrutta la relazione strutturale tra dimensione dell'immobile e numero di locali, mantenendo una coerenza geometrica delle superfici imputate.

Per **lift** (presenza di ascensore) si è sfruttata la relazione con il periodo di costruzione e il numero totale di piani dell'edificio. È stata costruita la variabile **period_of_construction** (classi di quantili dell'anno di costruzione) e si è analizzata la frequenza di ascensori per combinazioni di numero di piani e periodo. Sulla base di queste distribuzioni si è adottata una regola deterministica: negli edifici più bassi e più datati la mancanza di ascensore è stata considerata la situazione più probabile (imputando "no"), mentre negli edifici più recenti o con molti piani i valori mancanti sono stati imputati come "yes".

Per **conditions** (stato dell'immobile) si è sfruttata in modo intensivo la variabile testuale **other_features**. In una prima fase sono state ripulite e accorpate eventuali variabili dummy duplicate derivanti dall'estrazione di parole chiave, in modo che ogni caratteristica (es. tipo di infissi, presenza di allarme, camino, idromassaggio, arredi, ecc.) fosse rappresentata da una sola colonna binaria. A partire da tali dummy sono stati definiti gruppi logici che rappresentano quattro condizioni tipiche:

- combinazioni di dotazioni di alto livello tecnologico e di finitura (infissi di nuova generazione, fibra ottica, sistema di allarme, portone blindato, ecc.) associate allo stato "new / under construction" o "excellent / refurbished";
- combinazioni intermedie (balcone, cantina, infissi di qualità media, arredi parziali) associate a "good condition / liveable";
- combinazioni con assenza di dotazioni moderne, infissi datati e assenza di arredi interpretate come "to be refurbished".

Per le osservazioni con **conditions** mancante e profilo di caratteristiche coerente con uno di questi gruppi, è stato assegnato lo stato corrispondente. I residui mancanti (circa 70 casi) sono stati poi imputati in base all'anno di costruzione, assegnando per ciascun anno la modalità più frequente osservata (condizione "di moda" per quell'anno).

La variabile testuale **other_features** è stata anche utilizzata per un ampio lavoro di **feature engineering**. Innanzitutto, è stata scomposta in un elenco di parole chiave, da cui sono state create variabili binarie per la presenza di balconi, giardino, cantina, allarme, impianto TV, armadiatura/closet, cancello elettrico, servizio di portineria/accessibilità disabili, fibra ottica, porta blindata/reception, terrazzo, video-citofono, taverna, piscina, campo da tennis, camino e idromassaggio. Su queste dummy è stato stimato un modello lineare con **selling_price** come risposta, in modo da derivare un peso economico per ciascuna dotazione. Tali pesi sono stati poi utilizzati per costruire una variabile sintetica, **features_score**, ottenuta come combinazione lineare delle dotazioni presenti. Il punteggio è stato infine normalizzato per facilitarne l'uso nei modelli. Questa operazione permette di riassumere in un indice continuo l'effetto congiunto di numerose caratteristiche accessorie, evitando una proliferazione di dummy altamente correlate.

Sempre da **other_features** è stata derivata la variabile **exposure_score**, che quantifica la qualità dell'esposizione dell'immobile. Attraverso la ricerca di pattern testuali (internal/external exposure, orientamenti cardinali, double exposure) è stata definita una categoria di esposizione (nessuna, interna, esterna, nord, ovest, est, sud, doppia) alla quale è stato associato un punteggio crescente da 1 (nessuna esposizione particolare) a 4.5 (doppia esposizione). L'idea è catturare, in forma numerica, il valore di mercato associato a esposizioni più ricercate (ad esempio verso sud o con doppio affaccio).

Sempre a partire da **other_features** sono stati creati indicatori per il tipo di infissi e vetri (double/triple glass, materiale PVC, metallo, legno), in modo da rappresentare la qualità dell'isolamento termoacustico. Dopo avere estratto queste informazioni, la colonna testuale originale **other_features** è stata rimossa, poiché tutta l'informazione utile era stata trasferita in variabili strutturate.

Per **total_floors_in_building** si è innanzitutto uniformata la codifica trasformando la voce "1 floor" in 1 e convertendo la variabile in numerica. I valori mancanti sono stati imputati combinando logica edilizia e informazioni disponibili:

- negli edifici senza ascensore e senza spese condominiali si è imputato un solo piano;
 - negli edifici senza ascensore ma con spese condominiali positive si è imputato due piani;
 - per immobili a piano terra, seminterrato o rialzato con dato mancante, si è ipotizzato un edificio di almeno due piani;
 - nei casi rimanenti si è utilizzata l'informazione sul piano dell'unità abitativa (**floor**) per imputare un numero di piani almeno pari al piano in cui si trova l'alloggio.
- Queste regole mirano a mantenere la coerenza tra piano dell'abitazione e altezza complessiva dell'edificio.

Per **car_parking** è stata costruita una variabile numerica **parking_score** che sintetizza la disponibilità di posti auto. A partire dalla stringa descrittiva, sono stati estratti i numeri di posti "in garage/box" e "in shared parking" tramite espressioni regolari. È stato attribuito un peso maggiore ai posti in garage (peso 2) e minore a quelli in parcheggio condiviso (peso 1); in assenza di parcheggio

o di informazione è stato assegnato punteggio 0. In questo modo la variabile sintetizza quantitativamente e qualitativamente l'offerta di posti auto associata all'immobile. La variabile originaria **car_parking** è stata poi rimossa.

Per **condominium_fees** si è proceduto in più passaggi. Innanzitutto, la categoria "No condominium fees" è stata convertita in 0, e alcuni codici errati ("NaN") sono stati trattati come mancanti. La variabile è stata poi convertita in numerica. Tre valori estremi (250000, 200000, 110000) sono risultati incompatibili con il profilo degli immobili corrispondenti e sono stati ridotti dividendo per 1000, interpretandoli come probabili errori di inserimento. I valori mancanti sono stati trattati in modo differente: negli edifici con un solo piano si è imputato 0 (assenza plausibile di spese condominiali), mentre per le altre osservazioni si è imputata la mediana delle spese all'interno di ciascuna zona, sfruttando il fatto che condomini simili nella stessa area tendono ad avere costi comparabili.

Per **year_of_construction** si è lavorato indirettamente sulla variabile derivata **building_age**, calcolata come differenza tra l'anno corrente (2025) e l'anno di costruzione. I valori mancanti di **building_age** sono stati imputati in modo gerarchico: prima come mediana dell'età all'interno di ciascuna combinazione di zona e classe energetica, poi come mediana di zona e, infine, come mediana globale residua. Questo schema sfrutta la forte relazione tra periodo di costruzione, zona e classe energetica, riducendo la distorsione dovuta ai valori mancanti. Una volta derivata **building_age**, la variabile **year_of_construction** è stata rimossa.

Per **zone** è stata affrontata sia l'imputazione dei pochi valori mancanti sia una razionalizzazione delle categorie. L'unico caso con zona mancante è stato imputato assegnando "città studi", individuata come zona più plausibile sulla base di combinazioni di metratura, prezzo e stato dell'immobile. Successivamente è stata creata la variabile **zone_omi**, che aggrega le zone di annuncio in gruppi spaziali più ampi e coerenti con le zone OMI (Osservatorio del Mercato Immobiliare), tramite una mappatura manuale. Questa variabile è stata utilizzata per analisi esplorative (mappa dei prezzi medi per zona OMI) e come supporto alla comprensione della struttura spaziale dei prezzi. Infine, per la variabile **zone** destinata ai modelli, alcune aree molto piccole o rare sono state accorpate a zone limitrofe (ad esempio, "corso magenta" in "sant'ambrogio", "quadrilatero della moda" in "brera", ecc.), in modo da ridurre il numero di categorie sparse e mitigare il rischio di over fitting su livelli scarsamente rappresentati.

In aggiunta, a partire dalle coordinate geografiche derivate per ciascuna zona, sono state costruite due variabili spaziali chiave. La prima è **dist_duomo** definita come distanza in metri tra l'immobile e il Duomo di Milano: questa variabile cattura la graduale diminuzione dei prezzi all'aumentare della distanza dal centro storico. La seconda è **distance_metro**, che misura la distanza dal capolinea o fermata della metropolitana più vicina: è stata ottenuta trasformando coordinate di immobili e fermate in un sistema di riferimento metrico e computando per ogni immobile la distanza minima. Entrambe le variabili introducono una misura quantitativa dell'"accessibilità" e della centralità territoriale dell'abitazione.

Per **floor** si è resa numerica la posizione dell'unità abitativa nel palazzo: il seminterrato è stato codificato come -1, piano terra e mezzanino come 0, mentre i piani superiori sono stati convertiti in interi.

Per **heating_centralized** i valori mancanti sono stati imputati utilizzando una regola basata su età dell'edificio, numero di piani e spese condominiali. Si è ipotizzato che per edifici relativamente recenti, con molti piani e spese condominiali sopra la mediana sia maggiore la probabilità di avere riscaldamento centralizzato; negli altri casi è stato imputato il riscaldamento indipendente. In questo modo si sfruttano le correlazioni tra tipologia impiantistica, dimensione del condominio e oneri di gestione.

Per **energy_efficiency_class** è stata prima effettuata una pulizia delle stringhe (spazi e simboli superflui) e sono stati posti a NA i codici vuoti o anomali. Successivamente le classi sono state raggruppate in tre livelli ordinati **energy_efficiency_grouped** ("high" per classi A-B, "medium" per C-D, "low" per E-G), più adatti per la modellizzazione. I valori mancanti sono stati imputati in due passaggi: in primo luogo, assegnando all'interno di ciascuna combinazione di zona ed età dell'edificio la modalità più frequente osservata e, in seconda battuta, utilizzando la moda globale per i pochi casi ancora mancanti. Infine, la variabile è stata trasformata in numerica.

Al termine di queste operazioni, i dataset di training e test sono stati ricostruiti a partire dall'oggetto integrato **ds_intero**, in modo che tutte le imputazioni e le nuove variabili (**features_score**, **exposure_score**, **parking_score**, **building_age**, **dist_duomo**, **distance_metro**, ecc.) risultassero coerenti e calcolate con le stesse regole su entrambe le basi dati.

Modelli di previsione e risultati

In seguito alle operazioni di pulizia e imputazione, il dataset è stato ulteriormente raffinato eliminando alcune variabili ritenute ridondanti o poco utili ai fini predittivi (**energy_efficiency_class**, **zone_omi** e alcune dummy molto rare relative a dotazioni accessorie) e convertendo in fattori le principali variabili categoriali (**lift**, **availability**, **conditions**, **heating_centralized** e **zone**). Successivamente, il set di training è stato suddiviso ulteriormente in sottoinsiemi di training e validation (75%-25%) per poter stimare e confrontare i modelli in modo coerente.

Sono stati quindi sperimentati diversi modelli di complessità crescente, utilizzando come metrica di valutazione il Mean Absolute Error (MAE) sui prezzi di vendita nel validation set. Come benchmark è stato considerato un modello basato sulla sola mediana di **lpsm**, che fornisce un MAE nell'ordine di 170mila euro. Un primo modello lineare OLS "parsimonioso", con pochi predittori (**lift**, **floor**, **condominium_fees**, **bathrooms_number**, **rooms_number** e **dist_duomo**), riduce il MAE a circa 122mila euro, ma mostra come una forte semplificazione porti a perdere una parte rilevante dell'informazione contenuta nelle altre variabili. L'OLS completo, che include tutte le variabili disponibili dopo il pre-processing, migliora sensibilmente le prestazioni, portando il MAE a circa 81mila euro sul validation e costituendo il principale punto di riferimento tra i modelli lineari non penalizzati.

La backward regression è stata applicata al modello lineare per **lpsm**, dopo aver rimosso dalla design matrix le colonne perfettamente collineari. La procedura ha selezionato come covariate più persistenti alcune modalità di **conditions** e le variabili **garden** e **concierge_disabled_access**, individuando un modello ottimale con 23 predittori. Tuttavia, questo modello ha ottenuto un MAE sul validation di circa 140mila euro, sensibilmente peggiore rispetto all'OLS completo e alle regressioni penalizzate, indicando che in questo caso la riduzione automatica delle variabili tramite backward non migliora le prestazioni predittive.

Sono stati poi valutati metodi di regressione penalizzata e di riduzione dimensionale. Le regressioni Ridge, LASSO ed Elastic Net sono state stimate su una griglia di valori del parametro di penalizzazione λ , selezionando il valore ottimale tramite ricerca sul validation (e, nel caso della Ridge, anche tramite cross-validation interna). In tutti i casi i valori ottimali di λ risultano relativamente bassi, segnalando che la regolarizzazione necessaria per stabilizzare i coefficienti è moderata e che le soluzioni penalizzate restano vicine a quella OLS completa. I MAE ottenuti dai tre modelli (attorno a 81–82mila euro) sono molto simili tra loro e sostanzialmente allineati a quello dell'OLS completo, indicando una buona stabilità delle stime e assenza di overfitting marcato. La regressione PCR, applicata dopo la standardizzazione delle variabili, richiede un numero elevato di componenti principali per raggiungere prestazioni comparabili (fino a 175 componenti) e non fornisce miglioramenti tangibili rispetto ai modelli lineari classici, a fronte di una maggiore complessità interpretativa. Anche il modello LARS, che costruisce in modo efficiente un percorso di regressioni sparse, ottiene un MAE molto vicino a quello dei modelli penalizzati, con un numero ancora elevato di predittori effettivamente inclusi.

È stata infine considerata una famiglia di modelli più flessibili, i Generalized Additive Models (GAM), che consentono di modellare in modo non lineare alcune variabili continue mantenendo effetti lineari per le altre. Un primo GAM "semplice", con spline solo su **square_meters**, **dist_duomo**, **distance_metro** e **building_age**, migliora rispetto al benchmark ma si colloca ancora al di sopra dei modelli lineari completi, mostrando che le sole non-linearità sulle variabili continue non sono sufficienti senza includere le importanti informazioni categoriali. Il GAM completo, che combina smooth su variabili chiave (superficie, distanza dal Duomo, distanza dalla metro, età dell'edificio, numero di piani, spese condominiali e coordinate geografiche) con effetti lineari e fattoriali per tutte le altre variabili (bagni, stanze, features_score, exposure_score, zone, conditions, heating_centralized, energy_efficiency_grouped, lift, parking_score, garden, terrace e concierge_disabled_access) e utilizza la selezione automatica dei termini (select = TRUE), ottiene il miglior MAE sul validation, pari a circa 79mila euro. In entrambi i casi le spline hanno gradi di libertà $k = 10$, parametro che indica quanto flessibile può essere la curva: valori alti di k permettono di catturare più dettagli dei dati. Questo risultato suggerisce che un modello ibrido, capace di catturare sia non-linearità nelle variabili strutturali sia effetti categoriali complessi (in particolare legati alla localizzazione e allo stato dell'immobile), rappresenta la scelta più efficace per il problema in esame. In base a queste evidenze, il GAM completo è stato selezionato come modello finale per la generazione delle previsioni sul test set.

	Iper-parametri	MAE (VALIDATION)
Benchmark: mediana	-	170608.00
OLS modello ridotto	$p = 6$	121621.80
OLS modello completo	$p = 178$	81446.97
Backward Stepwise regression	$k = 23$	139975.10
PCR	$k = 175$	81446.96
Ridge regression	$\lambda = 0.006536829$	81328.43
Lasso regression	$\lambda = 0.002478752$	82112.92
LARS	$S = 156$	81341.84
Elastic Net	$\lambda = 0.0009399377$	81371.02
GAM ridotto	$k = 10$	107412.60
GAM completo	$k = 10$	79117.70

Conclusioni

L'analisi ha mostrato che un pre-processing accurato (imputazione mirata e variabili derivate, soprattutto geografiche e strutturali) migliora nettamente le prestazioni rispetto al benchmark basato sulla mediana dei prezzi. I modelli lineari su **lpsm** (OLS completo, penalizzati e LARS) forniscono MAE molto simili, intorno a 81mila euro sul validation, indicando che molte covariate apportano informazione utile e che la sola riduzione o penalizzazione non produce guadagni sostanziali. La backward regression, pur selezionando un sottoinsieme di variabili, peggiora sensibilmente l'accuratezza. Il GAM completo, che combina effetti non lineari sulle variabili continue con effetti lineari e categoriali, ottiene il MAE più basso (circa 79mila euro) e risulta quindi il modello più efficace, a costo di una maggiore complessità e minore immediatezza interpretativa.

- Il dataset utilizzato è disponibile su Kaggle al seguente link: <https://www.kaggle.com/competitions/immobiliare-data-mining-clamses-24-25>
- Rigon, T. Corso di Data Mining, CdL CLAMSES, Università degli Studi di Milano-Bicocca
- Shapefile Zone e perimetri OMI: <https://dati.comune.milano.it/dataset/ds2630-zone-e-perimetri-omi-2023-1>
- Shapefile Fermate linee metropolitane ATM: <https://dati.comune.milano.it/dataset/ds535-atm-fermate-linee-metropolitane>